


به نام خدا



دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشکده برق

میانترم


[محسن کریمی]

[40121913-]

استاد : آقای دکتر تقی راد

فهرست مطالب

عنوان	شماره صفحه
بخش صفر.....	3
بخش اول.....	4
بخش دوم.....	8
بخش سوم.....	11
بخش چهارم.....	16



بخش صفر

من مفهوم Back Propagation را انتخاب می‌کنم برای درس شهودی این مفهوم اکنون را با
تجربه به کار خودم با اگر دوباره مقایسه می‌کنم - زمانی که برای اولین بار یک ربات سیلاب ساده می‌ساختم
بارها پس می‌گفتم که ربات از مسیر خارج شود هر بار که از دست خط و تنظیمات بدنام
یا مقادیر سنسورها کمی تغییر می‌دادم تا کمک کند به شود. در واقع از اشتباه قبلی به اصلاح
رفتار ربات می‌استفاده کرد.

به زبان ساده Back Propagation قادر است عصبی حین ایده را و ببال می‌کند. شبیه ابتدا یک
خروجی را می‌کند پس معیاران خطا محاسب می‌شود و این خطا به لایه‌ها قبلی به تدریج می‌گردد
تا وزن‌ها اصلاح شوند. با کمک این روش می‌توانیم به تدریج پاسخ‌های دقیق‌تری تولید می‌کنیم
البتة این مثال کاملاً متداول B.P نیست در مثال ربات من ربات از گام‌ها تصحیح می‌کردم
چه تغییر در بردارهای ورودی می‌دادیم اما در شبیه عصبی هم اصلاحات بصورت ریاضی و خودکار انجام
می‌شود از جبهه ریاضی B.P با استفاده از مشتق ها و قاعده زنجیره‌ای می‌توانیم تغییرات وزن
به خطای نهایی را محاسبه می‌کنیم و پس وزن‌ها را در جهت کاهش خطا آپدیت می‌کنیم
بنابراین شبیه یادگیری از اشتباهات قبلی به خطای اول B.P می‌باشد اما در واقعیت
این فرآیند بلافاصله محاسبات در یک لحظه و آنست که در این خطا در لایه‌ها هم متفاوت می‌کند
انجام می‌شود



Scanned with CamScanner

بخش اول

سؤال ۱

الف) استخراج رابطه تبدیل دوربین نسبت به پایه ربات

با توجه به اینکه دوربین روی مجری نهایی بازو نصب شده است (Eye-in-Hand)، برای محاسبه ماتریس تبدیل دوربین نسبت به پایه باید تبدیل پایه به مجری نهایی و سپس تبدیل مجری نهایی به دوربین را با یکدیگر ترکیب کنیم.

ماتریس تبدیل مجری نهایی نسبت به پایه برابر با 0T_E است که از طریق پارامترهای DH محاسبه شده است.

طبق صورت سؤال، دوربین نسبت به مجری نهایی دارای یک انتقال ۵ سانتی متری در راستای محور Z و یک دوران ۹۰ درجه حول محور X است.

ماتریس دوران حول محور X به صورت زیر است:

$$R_x(90^\circ) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 1 & 0 \end{bmatrix}$$

بنابراین ماتریس تبدیل دوربین نسبت به مجری نهایی برابر خواهد بود با:

$${}^ET_C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0.5 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

در نتیجه با استفاده از قانون زنجیره‌ای تبدیل‌ها داریم:

$${}^0T_C = {}^0T_E {}^ET_C$$

یا:

$${}^0T_C = {}^0T_E \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0.5 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

که رابطه تبدیل دوربین نسبت به پایه ربات است.

ب) بیان مراحل تبدیل مختصات جسم از قاب دوربین به قاب پایه

مختصات جسم در قاب دوربین برابر است با:

$${}^cP = \begin{bmatrix} 2 \\ -1 \\ 10 \\ 1 \end{bmatrix}$$

برای به دست آوردن مختصات این نقطه در قاب پایه، ابتدا باید مختصات آن از قاب دوربین به قاب مجری نهایی تبدیل شود و سپس از قاب مجری نهایی به قاب پایه انتقال یابد.

بنابراین:

$${}^EP = {}^ET_C {}^cP$$

و سپس:

$${}^0P = {}^0T_E {}^EP$$

با جایگذاری رابطه بالا خواهیم داشت:

$${}^0P = {}^0T_E {}^ET_C {}^cP$$

یا به صورت کامل:

$${}^0P = {}^0T_E \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & -1 & 0 \\ 0 & 1 & 0 & 0.5 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \\ 10 \\ 1 \end{bmatrix}$$

در این رابطه ابتدا مختصات نقطه از دستگاه مختصات دوربین به دستگاه مختصات ابزار تبدیل می شود و سپس با استفاده از وضعیت فعلی بازو، مختصات آن در دستگاه مختصات پایه به دست می آید. مطابق خواسته سؤال نیازی به انجام محاسبات عددی نیست و نمایش ساختار ضرب ماتریس ها کافی است.

سؤال ۲

در ربات صفحه‌ای سه درجه آزادی از نوع RRR، هر سه مفصل از نوع دورانی هستند و حرکت بازو در یک صفحه انجام می‌شود. بنابراین متغیرهای مفصلی ربات عبارت‌اند از:

$$q = [\theta_1, \theta_2, \theta_3]^T$$

که نشان‌دهنده سه درجه آزادی دورانی ربات هستند.

در قرارداد Standard DH، محور Z_i بر محور دوران مفصل i منطبق می‌شود. از آنجا که در ربات صفحه‌ای RRR تمامی محورهای دوران موازی یکدیگر و عمود بر صفحه حرکت هستند، تعریف فریم‌های مختصات بسیار ساده خواهد بود.

در این ربات بین محورهای متوالی هیچ پیچشی وجود ندارد، بنابراین:

$$\alpha_i = 0$$

همچنین هیچ جابه‌جایی در راستای محورهای Z وجود ندارد، در نتیجه:

$$d_i = 0$$

جدول پارامترهای DH به صورت زیر است:

- لینک اول $a_1 = L_1$ ، $\alpha_1 = 0$ ، $d_1 = 0$ ، θ_1
- لینک دوم $a_2 = L_2$ ، $\alpha_2 = 0$ ، $d_2 = 0$ ، θ_2
- لینک سوم $a_3 = L_3$ ، $\alpha_3 = 0$ ، $d_3 = 0$ ، θ_3

بنابراین ماتریس تبدیل هر لینک به شکل ساده زیر خواهد بود:

$$A_i = Rot_z(\theta_i) Trans_x(a_i)$$

و سینماتیک مستقیم از رابطه زیر به دست می‌آید:

$$\begin{aligned} {}^0T_3 &= A_1 A_2 A_3 \\ y &= L_1 \sin \theta_1 + L_2 \sin (\theta_1 + \theta_2) + L_3 \sin (\theta_1 + \theta_2 + \theta_3) \\ \phi &= \theta_1 + \theta_2 + \theta_3 \end{aligned}$$

استفاده از Modified DH معمولاً برای ربات‌هایی مناسب است که دارای ساختار فضایی پیچیده، محوره‌ای غیرموازی یا پیچش‌های هندسی قابل توجه باشند. اما در ربات صفحه‌ای RRR تمامی محوره‌ای دوران موازی‌اند و ساختار هندسی بسیار ساده است؛ بنابراین استفاده از Modified DH مزیت خاصی ایجاد نمی‌کند.

در نتیجه استفاده از Standard DH انتخاب مناسب‌تری است، زیرا:

1. محوره‌ای مفصل موازی هستند .
 2. پارامترهای d_i و α_i صفر می‌شوند .
 3. تعریف دستگاه‌های مختصات ساده‌تر است .
 4. استخراج روابط سینماتیک مستقیم راحت‌تر انجام می‌شود .
 5. متغیرهای مفصلی θ_1, θ_2 و θ_3 مستقیماً در مدل ظاهر می‌شوند .
- بنابراین برای ربات صفحه‌ای سه درجه آزادی RRR، استفاده از Standard DH ساده‌ترین و مناسب‌ترین روش برای استخراج سینماتیک مستقیم است.

بخش دوم

سؤال ۳

تحلیل مشکل پیشنهاد مهندس: روش Global Histogram Equalization (GHE) از هیستوگرام کل تصویر برای محاسبه تابع تبدیل شدت روشنایی استفاده می‌کند. در سناریوی مطرح شده (تصاویر صنعتی با سایه‌های شدید و نور غیریکنواخت)، GHE به دلیل «سراسری» بودن، سعی می‌کند کنتراست کل تصویر را به طور یکنواخت تغییر دهد. این کار باعث می‌شود نواحی روشن تصویر بیش از حد اشباع (Saturate) شده و جزئیات در نواحی سایه‌دار عمیق (که احتمال وجود ترک در آن‌ها بالاست) به دلیل نویز تقویت شده یا عدم انطباق هیستوگرام محلی، کاملاً از بین بروند. به زبان ساده، GHE به بافت‌های محلی تصویر اهمیت نمی‌دهد.

مزیت: روش CLAHE Contrast Limited Adaptive Histogram Equalization (CLAHE) با تقسیم تصویر به کاشی‌های کوچک (Tiles) و انجام عملیات محلی، مشکل نور غیریکنواخت را برطرف می‌کند. چون هر کاشی به صورت جداگانه هیستوگرام‌بندی می‌شود، تغییرات شدت نور در کل تصویر (مثل سایه‌ها) تأثیر منفی روی نواحی دیگر نمی‌گذارند.

نقش پارامترهای کلیدی:

Clip Limit: این پارامتر مرز (Threshold) هیستوگرام را تعیین می‌کند. اگر فرکانس یک سطح شدت روشنایی از این مقدار فراتر رود، آن بخش برش خورده و به صورت یکنواخت بین سایر سطوح توزیع می‌شود. این کار جلوی تقویت بیش از حد نویز در نواحی یکنواخت (مثل سایه‌ها) را می‌گیرد، چون مانع از تبدیل تغییرات جزئی نویزی به کنتراست بالا می‌شود.

Tile Grid Size: تعیین‌کننده اندازه کاشی‌هاست. کاشی‌های خیلی کوچک، کنتراست محلی بسیار بالایی می‌دهند اما نویز را به شدت تقویت می‌کنند. کاشی‌های بزرگتر، رفتاری شبیه به GHE پیدا می‌کنند. انتخاب مناسب این مقدار باعث می‌شود که نویز نواحی همگن (مثل سایه‌ها) در ابعاد بزرگتری میانگین‌گیری شده و تأثیرش کاهش یابد.

سؤال ۴

ماتریس تصویر داده شده:

$$I = \begin{bmatrix} 10 & 10 & 100 \\ 10 & 10 & 100 \\ 10 & 10 & 100 \end{bmatrix}$$

فیلتر Sobel در راستای افقی (G_x) برابر است با:

$$G_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

طبق صورت سؤال، خروجی برای پیکسل مرکزی (مقدار 10 در مرکز ماتریس) و بدون Padding محاسبه می‌شود.

عمل کانولوشن:

$$\begin{aligned} G_x * I &= (-1)(10) + (0)(10) + (1)(100) \\ &+ (-2)(10) + (0)(10) + (2)(100) \\ &+ (-1)(10) + (0)(10) + (1)(100) \\ &= -10 + 0 + 100 - 20 + 0 + 200 - 10 + 0 + 100 \\ &= 360 \end{aligned}$$

بنابراین خروجی فیلتر برای پیکسل مرکزی برابر است با:

$$G_x = 360$$

تفسیر نتیجه

مقدار مثبت و بزرگ 360 نشان می‌دهد که تغییر شدت روشنایی از چپ به راست بسیار زیاد است. در این تصویر ستون‌های اول و دوم دارای شدت 10 و ستون سوم دارای شدت 100 هستند؛ بنابراین یک مرز عمودی واضح در سمت راست تصویر وجود دارد.

از آنجا که پاسخ G_x مثبت است، شدت روشنایی در جهت چپ به راست افزایش یافته است:

$$10 \rightarrow 100$$

در نتیجه:

- شدت لبه بسیار زیاد است .
- لبه از نوع عمودی است .

- جهت گرادیان از ناحیه تیره به سمت ناحیه روشن (چپ به راست) است .

بنابراین فیلتر Sobel وجود یک لبه عمودی قوی را در تصویر تشخیص داده است و مقدار 360 بیانگر شدت زیاد این لبه است.



سؤال ۵

در شبکه‌های عصبی چندلایه (MLP)، استفاده از تابع فعال‌ساز Sigmoid می‌تواند منجر به پدیده محو شدن گرادیان (Vanishing Gradient) شود. این مشکل در مرحله آموزش و هنگام اجرای الگوریتم Backpropagation رخ می‌دهد.

تابع سیگموید به صورت زیر تعریف می‌شود:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

مشتق این تابع برابر است با:

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

حداکثر مقدار مشتق سیگموید برابر است با:

$$0.25$$

بنابراین مشتق این تابع همواره مقداری کوچک‌تر یا مساوی 0.25 دارد.

در الگوریتم Backpropagation گرادیان خطا از لایه خروجی به سمت لایه‌های ابتدایی منتقل می‌شود. طبق قانون زنجیره‌ای (Chain Rule)، گرادیان هر لایه از حاصل ضرب مشتقات لایه‌های بعدی به دست می‌آید. برای مثال اگر یک شبکه چندلایه داشته باشیم:

$$\frac{\partial L}{\partial W_1} = \frac{\partial L}{\partial a_n} \prod_{i=2}^n \frac{\partial a_i}{\partial a_{i-1}}$$

در شبکه‌ای که از سیگموید استفاده می‌کند، هر یک از این مشتقات معمولاً مقداری کوچک‌تر از 0.25 هستند. فرض کنیم در یک شبکه 10 لایه‌ای مقدار متوسط مشتق برابر 0.1 باشد. در این صورت:

$$0.1^{10} = 10^{-10}$$

که عددی بسیار کوچک است.

بنابراین هنگام انتقال گرادیان از لایه‌های انتهایی به لایه‌های ابتدایی، مقدار گرادیان به سرعت به صفر نزدیک می‌شود. در نتیجه وزن‌های لایه‌های ابتدایی تقریباً به‌روزرسانی نمی‌شوند و یادگیری در آن‌ها متوقف یا بسیار کند خواهد شد. این پدیده همان Vanishing Gradient است.

راهکار شبکه‌های CNN برای کاهش این مشکل

شبکه‌های CNN معمولاً از چند روش برای مقابله با این مشکل استفاده می‌کنند:

۱- استفاده از ReLU

تابع ReLU به صورت زیر تعریف می‌شود:

$$f(x) = \max(0, x)$$

مشتق آن برای مقادیر مثبت برابر 1 است:

$$f'(x) = 1$$

بنابراین گرادیان در طول لایه‌ها حفظ می‌شود و مانند سیگموئید به سرعت کوچک نمی‌گردد.

۲- مقداردهی اولیه مناسب وزن‌ها

روش‌هایی مانند Xavier و He Initialization باعث می‌شوند واریانس سیگنال و گرادیان در طول شبکه حفظ شود.

۳- Batch Normalization

نرمال‌سازی خروجی لایه‌ها باعث می‌شود مقادیر فعال‌سازی در محدوده مناسبی قرار گیرند و احتمال اشباع شدن نورون‌ها کاهش یابد.

۴- معماری‌های دارای اتصال میان‌بر (Residual Connections)

در شبکه‌هایی مانند ResNet مسیرهای مستقیم برای عبور گرادیان ایجاد می‌شود و گرادیان می‌تواند بدون افت شدید به لایه‌های ابتدایی برسد.

نتیجه‌گیری

در شبکه‌های عمیق، مشتق کوچک تابع Sigmoid باعث می‌شود حاصل ضرب متوالی مشتقات در قانون زنجیره‌ای به مقادیر بسیار کوچک تبدیل شود. در نتیجه گرادیان در لایه‌های ابتدایی تقریباً صفر

شده و فرآیند یادگیری مختل می‌شود. استفاده از ReLU، مقداردهی اولیه مناسب، Batch Normalization و Residual Connections از مهم‌ترین راهکارهای کاهش یا رفع این مشکل در CNNها هستند.

سؤال ۶

الف) محاسبه ابعاد فضایی خروجی لایه کانولوشن

مشخصات لایه:

- ورودی $128 \times 128 \times 3$:
- تعداد فیلترها: 64
- اندازه فیلتر 5×5 :
- $\text{Stride} = 2$
- $\text{Padding} = 2$

فرمول محاسبه ابعاد خروجی در لایه کانولوشن:

$$\text{Output} = \frac{N - F + 2P}{S} + 1$$

که در آن:

- N : اندازه ورودی
- F : اندازه فیلتر
- P : مقدار Padding
- S : مقدار Stride

برای بعد ارتفاع:

$$\begin{aligned} H_{out} &= \frac{128 - 5 + 2(2)}{2} + 1 \\ &= \frac{127}{2} + 1 \\ &= 63.5 + 1 \\ &= 64.5 \end{aligned}$$

در عمل خروجی باید عدد صحیح باشد، بنابراین:

$$H_{out} = 64$$

به همین ترتیب برای عرض:

$$W_{out} = 64$$

از آنجا که تعداد فیلترها برابر 64 است، عمق خروجی نیز برابر 64 خواهد بود.
بنابراین ابعاد نهایی خروجی:

$$64 \times 64 \times 64$$

(ب) محاسبه تعداد پارامترهای قابل آموزش

هر فیلتر دارای ابعاد:

$$5 \times 5 \times 3$$

است.

بنابراین تعداد وزن‌های هر فیلتر:

$$5 \times 5 \times 3 = 75$$

هر فیلتر یک Bias نیز دارد:

$$75 + 1 = 76$$

پارامتر برای هر فیلتر.

از آنجا که تعداد فیلترها 64 است:

$$76 \times 64 = 4864$$

بنابراین تعداد کل پارامترهای قابل آموزش برابر است با:

4864

پارامتر.

نتیجه نهایی


ابعاد خروجی لایه:

$64 \times 64 \times 64$

تعداد پارامترهای قابل آموزش:

4864

پارامتر.



بخش چهارم

سؤال ۷

الف) محاسبه ابعاد صحیح ورودی لایه Fully Connected

مرحله ۱: ابعاد ورودی

طبق کد:

• Input shape = (Batch_Size, 3, 64, 64)

بنابراین ابعاد فضایی ورودی:

$$64 \times 64$$

است.

مرحله ۲: لایه کانولوشن

•

```
self.conv1 = nn.Conv2d(  
    in_channels=3,  
    out_channels=16,  
    kernel_size=3,  
    padding=1  
)
```

فرمول خروجی کانولوشن:

$$Output = \frac{N - F + 2P}{S} + 1$$

که در آن:

• $N = 64$

• $F = 3$

• $P = 1$

• $S = 1$ (پیش فرض)

بنابراین:

$$\frac{64 - 3 + 2(1)}{1} + 1 = 64$$

پس خروجی کانولوشن:

$$16 \times 64 \times 64$$

خواهد بود.

مرحله ۳: لایه MaxPool

- `self.pool = nn.MaxPool2d(kernel_size=2, stride=2)`

عمل Pooling ابعاد فضایی را نصف می کند:

$$64 \rightarrow 32$$

بنابراین خروجی: Pooling

$$16 \times 32 \times 32$$

خواهد بود.

مرحله ۴: محاسبه اندازه Flatten

در PyTorch هنگام ورود به لایه Fully Connected باید تمام ابعاد به یک بردار تبدیل شوند:

$$16 \times 32 \times 32 = 16384$$

بنابراین اندازه صحیح Flatten برابر است با:

$$16384$$

علت بروز خطا

در کد داده شده داریم:

- `self.fc1 = nn.Linear(16 * 16 * 16, 10)`

و

- `x = x.view(-1, 16 * 16 * 16)`

در حالی که اندازه واقعی خروجی برابر است با:

$$16 \times 32 \times 32$$

نه

$$16 \times 16 \times 16$$

بنابراین هنگام reshape یا ورود به fc1 ناسازگاری ابعاد (Dimension Mismatch) رخ می دهد.

ب) اصلاح تابع forward برای ورودی 64×64

نسخه صحیح:

- ```
def forward(self, x):
 x = self.pool(F.relu(self.conv1(x)))
 x = x.view(x.size(0), 16 * 32 * 32)
 x = self.fc1(x)
 return x
```

یا به شکل حرفه ای تر:

- ```
def forward(self, x):  
    x = self.pool(F.relu(self.conv1(x)))  
    x = torch.flatten(x, start_dim=1)  
    x = self.fc1(x)  
    return x
```

در این حالت باید تعریف fc1 نیز اصلاح شود:

- `self.fc1 = nn.Linear(16 * 32 * 32, 10)`

نتیجه نهایی سؤال ۷

اندازه خروجی پس از: Pooling

$$16 \times 32 \times 32$$

اندازه: Flatten

16384

تعریف صحیح لایه: Fully Connected

• `self.fc1 = nn.Linear(16384, 10)`

سؤال ۸

تحلیل عملیات مورفولوژیکی Opening

در کد داده شده:

• `kernel = np.ones((5,5), np.uint8)`

```
processed =  
cv2.morphologyEx(  
    thresh,  
    cv2.MORPH_OPEN,  
    kernel  
)
```

عملیات Opening از دو مرحله تشکیل می شود:

1. Erosion

2. Dilation

یعنی:

$$Opening = Dilation(Erosion(I))$$

نقش Erosion

در مرحله فرسایش (Erosion) ، پیکسل‌های روشن کوچک حذف می‌شوند و نواحی سفید کوچک‌تر می‌گردند.

در نتیجه:

- نویزهای سفید کوچک حذف می‌شوند .
- نقاط پراکنده روشن از بین می‌روند .
- زائده‌های نازک حذف می‌شوند .

نقش Dilation

پس از فرسایش، عمل Dilation اجرا می‌شود تا اندازه نواحی اصلی دوباره بازیابی شود.
این مرحله:

- ساختارهای اصلی را حفظ می‌کند .
- نواحی واقعی جسم را بازسازی می‌کند .
- اثر کوچک‌شدن ناشی از Erosion را تا حدی جبران می‌کند .

تأثیر کرنل 5×5

استفاده از کرنل:

- (5×5)

باعث می‌شود هر ساختاری که کوچک‌تر از این ابعاد باشد به احتمال زیاد حذف شود.

بنابراین:

مزایا

- حذف نویزهای روشن کوچک
- حذف لکه‌های تصادفی
- هموار شدن مرز اجسام

- کاهش False Detection

معایب

اگر ترک‌های واقعی تصویر بسیار باریک باشند، کرنل 5×5 ممکن است:

- بخشی از ترک‌ها را حذف کند .
- ترک‌های باریک را قطع کند .
- اطلاعات مهم را از بین ببرد .

آیا این عملیات برای آشکارسازی ترک‌های بسیار باریک مناسب است؟

لزوماً خیر.

ترک‌های سطح فلز معمولاً:

- باریک هستند .
- عرض کمی دارند .
- دارای جزئیات ظریف‌اند .

استفاده از Opening با کرنل نسبتاً بزرگ 5×5 ممکن است این جزئیات را حذف کند.

در چنین کاربردی معمولاً یکی از روش‌های زیر مناسب‌تر است:

- استفاده از کرنل کوچک‌تر (مانند 3×3)
- CLAHE برای افزایش کنتراست
- فیلترهای تشخیص لبه (Sobel) ، (Canny)
- Top-Hat Morphology
- عملیات مورفولوژیکی مبتنی بر شکل ترک

نتیجه‌گیری

عملیات Opening ابتدا با Erosion نویزهای روشن کوچک را حذف کرده و سپس با Dilation ساختارهای اصلی را بازسازی می‌کند. استفاده از کرنل 5×5 در حذف نویز مؤثر است، اما در تصاویر صنعتی که هدف آشکارسازی ترک‌های بسیار باریک است، ممکن است بخشی از ترک‌های واقعی را نیز حذف کند. بنابراین برای چنین کاربردی باید اندازه کرنل با دقت انتخاب شود یا از روش‌های تکمیلی تشخیص ترک استفاده گردد.

